

Point: 단계별 데이터 이름을 다르게 지정하여
각 단계의 데이터를 보존하도록 함

“독성 버섯의 이진예측”

분석 목표: 버섯 특성 데이터를 기반으로
독성 여부를 예측하고 중요한 변수를 식별

데이터:

<https://www.kaggle.com/competitions/playground-series-s4e8>

“Binary Prediction of Poisonous Mushrooms”

202110456

강유진

1. 데이터 로드

```
##데이터 둘러보기
```

```
raw_df = read.csv('c:/Users/yujin/Desktop/4학년 1학기/전산실습/1차프로젝트 데이터/train.csv')  
str(raw_df)
```

컬럼별의미

```
'data.frame': 3116945 obs. of 22 variables:  
 $ id          : int  0 1 2 3 4 5 6 7 8 9 ...  
 $ class       : chr  "e" "p" "e" "e" ...  
 $ cap.diameter : num  8.8 4.51 6.94 3.88 5.85 4.3 9.65 4.55 7.36 6.45 ...  
 $ cap.shape   : chr  "f" "x" "f" "f" ...  
 $ cap.surface : chr  "s" "h" "s" "y" ...  
 $ cap.color   : chr  "u" "o" "b" "g" ...  
 $ does.bruise.or.bleed: chr  "f" "f" "f" "f" ...  
 $ gill.attachment : chr  "a" "a" "x" "s" ...  
 $ gill.spacing : chr  "c" "c" "c" "" ...  
 $ gill.color   : chr  "w" "n" "w" "g" ...  
 $ stem.height  : num  4.51 4.79 6.85 4.16 3.37 ...  
 $ stem.width   : num  15.39 6.48 9.93 6.53 8.36 ...  
 $ stem.root    : chr  "" "" "" "" ...  
 $ stem.surface : chr  "" "y" "s" "" ...  
 $ stem.color   : chr  "w" "o" "n" "w" ...  
 $ veil.type    : chr  "" "" "" "" ...  
 $ veil.color   : chr  "" "" "" "" ...  
 $ has.ring     : chr  "f" "t" "f" "f" ...  
 $ ring.type    : chr  "f" "z" "f" "f" ...  
 $ spore.print.color : chr  "" "" "" "" ...  
 $ habitat     : chr  "d" "d" "l" "d" ...  
 $ season      : chr  "a" "w" "w" "u" ...
```

id: 각 버섯의 고유 식별자.

class: 독성 여부, 'e' (식용 가능), 'p' (독성).

cap-diameter: 버섯의 갓 지름 (숫자형, cm).

cap-shape: 갓 모양 (예: f, x, p 등).

cap-surface: 갓 표면의 질감 (예: s, y, h 등).

cap-color: 갓의 색상 (예: u, o, n 등).

does-bruise-or-bleed: 멍이 들거나 진물이 나오는지 (예: f, t).

gill-attachment: 주름이 자라는 방식 (예: a, s).

gill-spacing: 주름 간격 (예: c, w 등).

gill-color: 주름의 색상 (예: w, g 등).

stem-height: 줄기의 높이 (숫자형, cm).

stem-width: 줄기의 너비 (숫자형, cm).

stem-root: 줄기의 뿌리 형태.

stem-surface: 줄기의 표면 질감.

stem-color: 줄기의 색상.

veil-type: 줄기를 감싸는 얇은 막의 유형.

veil-color: 막의 색상.

has-ring: 줄기 주변의 고리가 있는지 여부.

ring-type: 고리의 종류.

spore-print-color: 포자 색상.

habitat: 서식지 유형 (예: d, l, g 등).

season: 계절 (예: a, w 등).

1. 데이터 로드

```
##데이터 둘러보기
```

```
raw_df = read.csv('c:/Users/yujin/Desktop/4학년 1학기/전산실습/1차프로젝트 데이터/train.csv')  
str(raw_df)
```

컬럼별의미

```
'data.frame': 3116945 obs. of 22 variables:  
 $ id          : int  0 1 2 3 4 5 6 7 8 9 ...  
 $ class       : chr  "e" "p" "e" "e" ...  
 $ cap.diameter : num  8.8 4.51 6.94 3.88 5.85 4.3 9.65 4.55 7.36 6.45 ...  
 $ cap.shape    : chr  "f" "x" "f" "f" ...  
 $ cap.surface  : chr  "s" "h" "s" "y" ...  
 $ cap.color    : chr  "u" "o" "b" "g" ...  
 $ does.bruise.or.bleed: chr  "f" "f" "f" "f" ...  
 $ gill.attachment : chr  "a" "a" "x" "s" ...  
 $ gill.spacing  : chr  "c" "c" "c" "" ...  
 $ gill.color    : chr  "w" "n" "w" "g" ...  
 $ stem.height  : num  4.51 4.79 6.85 4.16 3.37 ...  
 $ stem.width    : num  15.39 6.48 9.93 6.53 8.36 ...  
 $ stem.root     : chr  "" "" "" "" ...  
 $ stem.surface  : chr  "" "y" "s" "" ...  
 $ stem.color    : chr  "w" "o" "n" "w" ...  
 $ veil.type     : chr  "" "" "" "" ...  
 $ veil.color    : chr  "" "" "" "" ...  
 $ has.ring      : chr  "f" "t" "f" "f" ...  
 $ ring.type     : chr  "f" "z" "f" "f" ...  
 $ spore.print.color : chr  "" "" "" "" ...  
 $ habitat      : chr  "d" "d" "l" "d" ...  
 $ season       : chr  "a" "w" "w" "u" ...
```

id: 각 버섯의 고유 식별자.

class: 독성 여부, 'e' (식용 가능), 'p' (독성).

cap-diameter: 버섯의 갓 지름 (숫자형, cm).

cap-shape: 갓 모양 (예: f, x, p 등).

cap-surface: 갓 표면의 질감 (예: s, y, h 등).

cap-color: 갓의 색상 (예: u, o, n 등).

does-bruise-or-bleed: 멍이 들거나 진물이 나오는지 (예: f, t).

gill-attachment: 주름이 자라는 방식 (예: a, s).

gill-spacing: 주름 간격 (예: c, w 등).

gill-color: 주름의 색상 (예: w, g 등).

stem-height: 줄기의 높이 (숫자형, cm).

stem-width: 줄기의 너비 (숫자형, cm).

stem-root: 줄기의 뿌리 형태.

stem-surface: 줄기의 표면 질감.

stem-color: 줄기의 색상.

veil-type: 줄기를 감싸는 얇은 막의 유형.

veil-color: 막의 색상.

has-ring: 줄기 주변의 고리가 있는지 여부.

ring-type: 고리의 종류.

spore-print-color: 포자 색상.

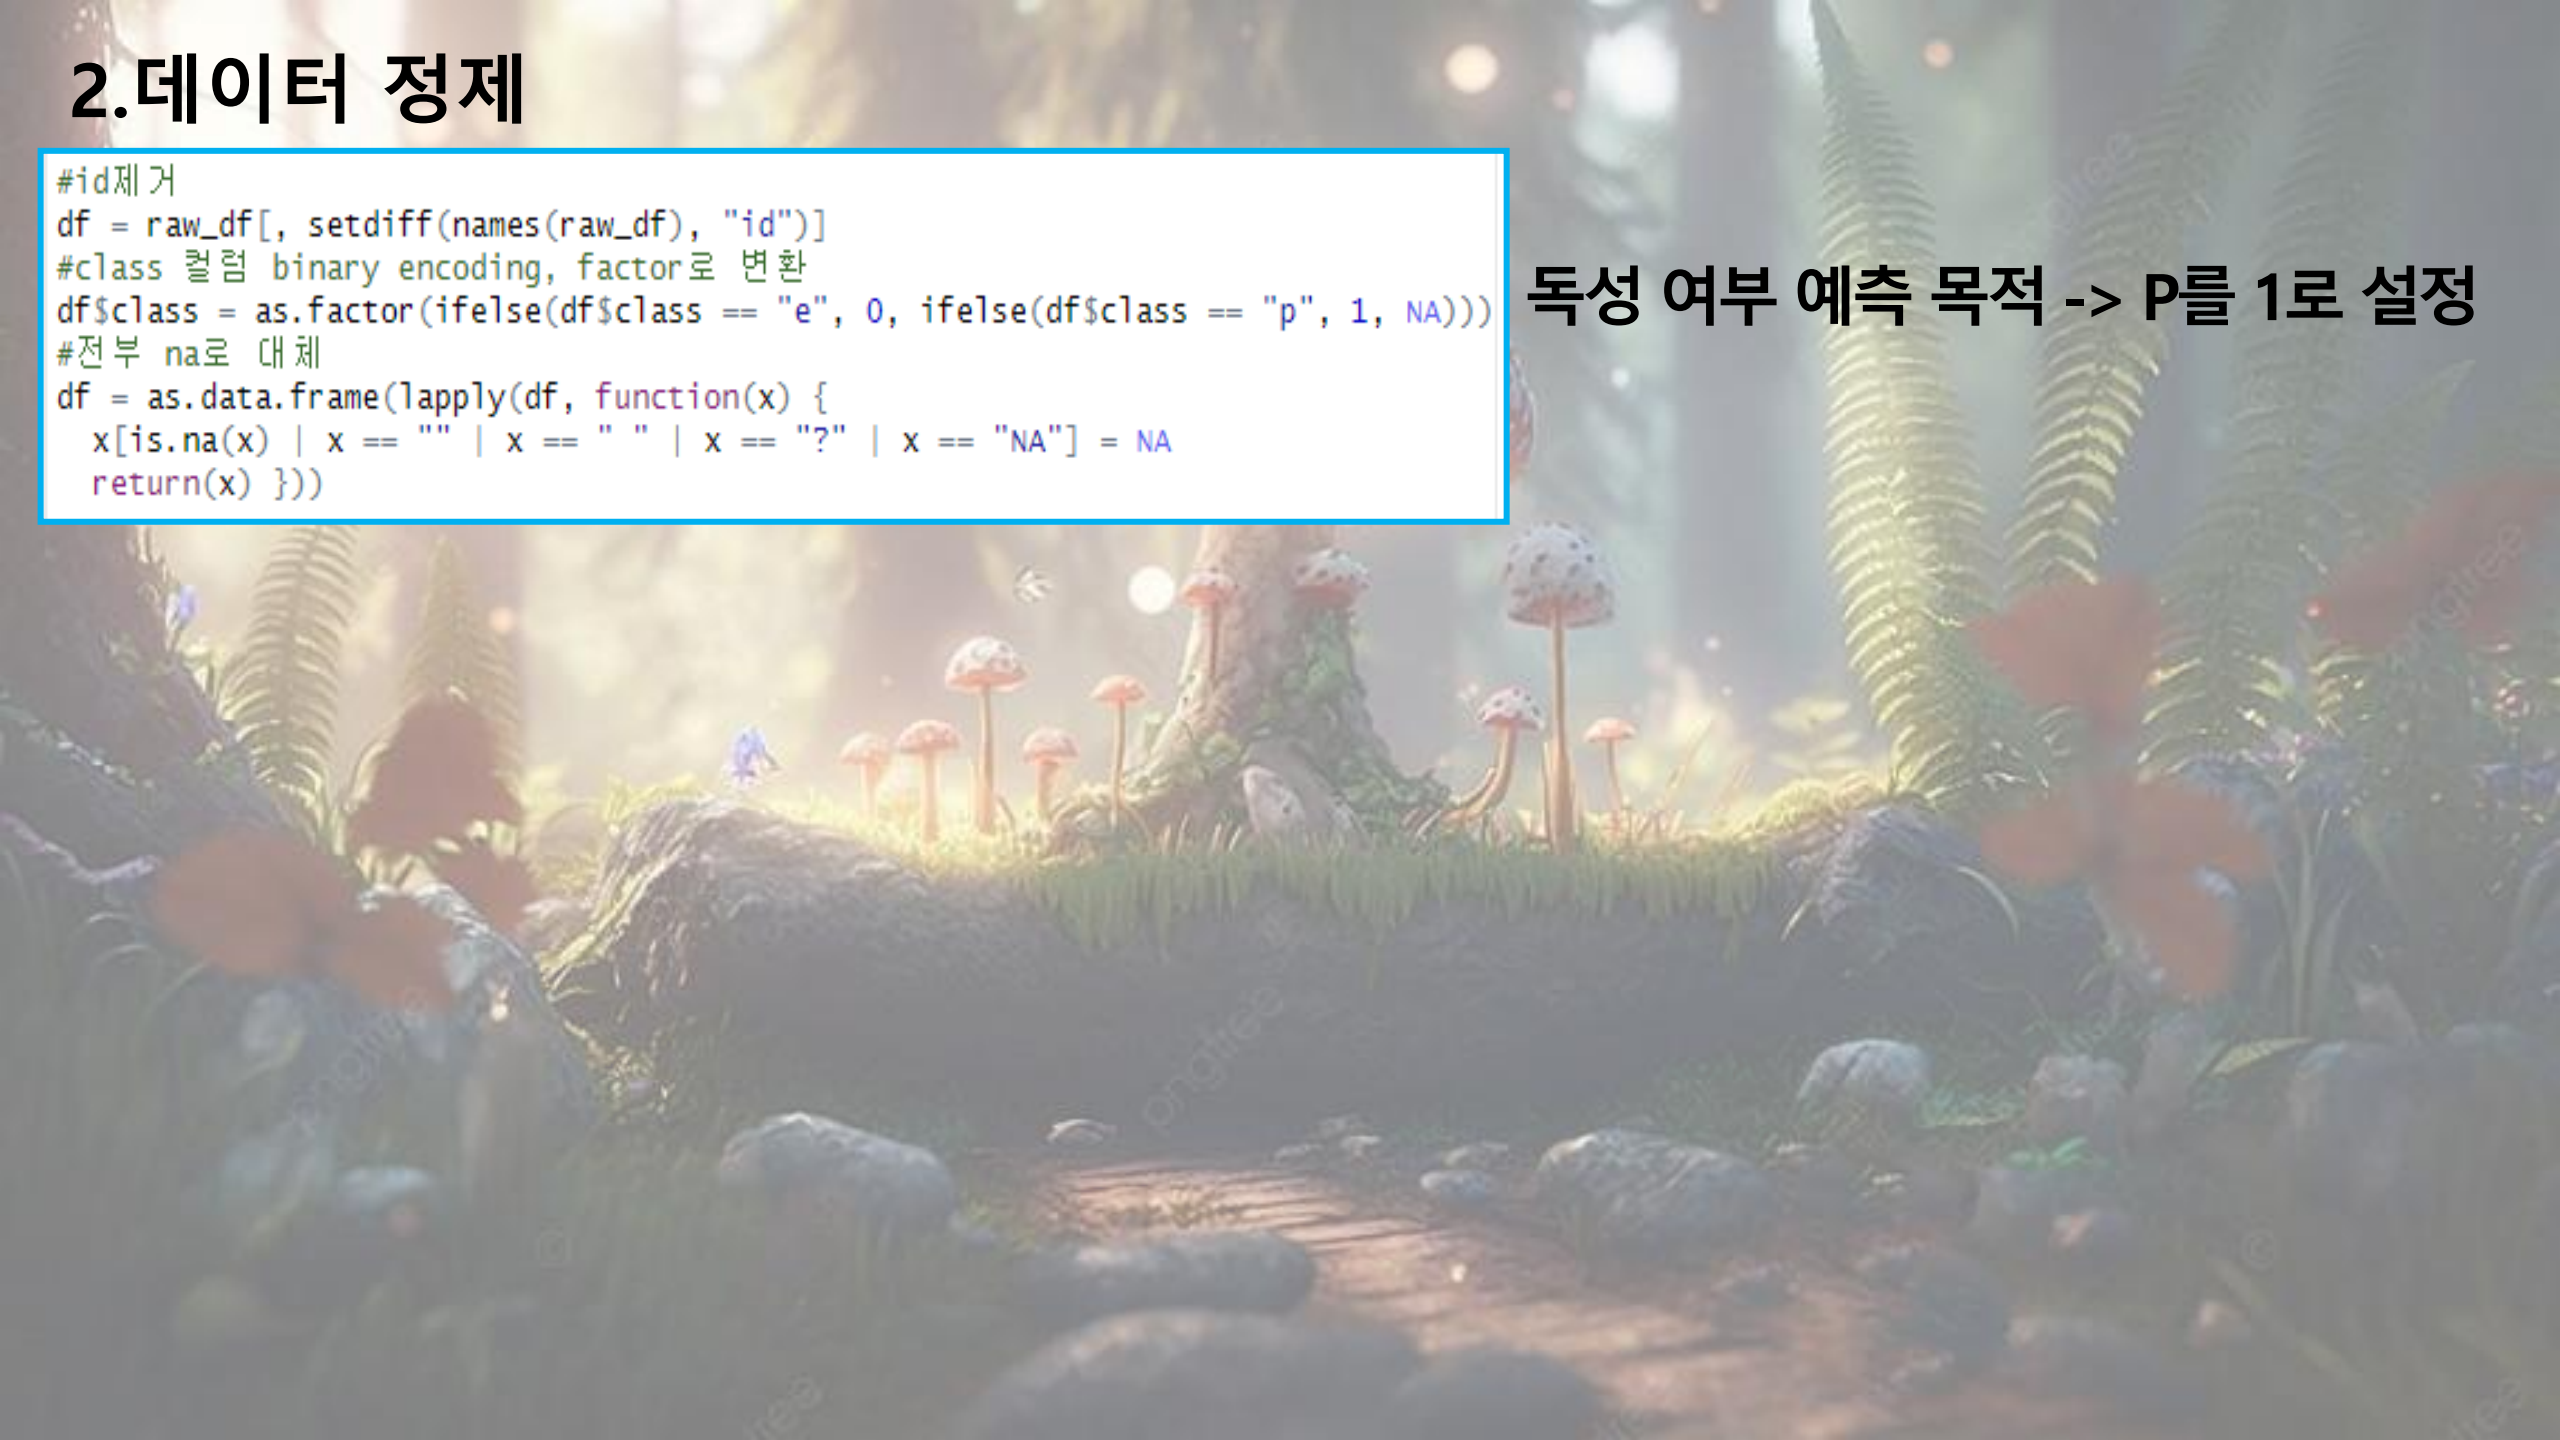
habitat: 서식지 유형 (예: d, l, g 등).

season: 계절 (예: a, w 등).

2.데이터 정제

```
#id제거
df = raw_df[, setdiff(names(raw_df), "id")]
#class 컬럼 binary encoding, factor로 변환
df$class = as.factor(ifelse(df$class == "e", 0, ifelse(df$class == "p", 1, NA)))
#전부 na로 대체
df = as.data.frame(lapply(df, function(x) {
  x[is.na(x) | x == "" | x == " " | x == "?" | x == "NA"] = NA
  return(x) })))
```

독성 여부 예측 목적 -> P를 1로 설정



2.데이터 정제

```
#id제거
df = raw_df[, setdiff(names(raw_df), "id")]
#class 컬럼 binary encoding, factor로 변환
df$class = as.factor(ifelse(df$class == "e", 0, ifelse(df$class == "p", 1, NA)))
#전부 na로 대체
df = as.data.frame(lapply(df, function(x) {
  x[is.na(x) | x == "" | x == " " | x == "?" | x == "NA"] = NA
  return(x) })))
```

독성 여부 예측 목적 -> P를 1로 설정

피쳐요약표

2.1 결측치 처리

```
#피쳐요약표 생성 및 출력
resumetable = function(df) {
  summary_table = data.frame(
    데이터_타입 = sapply(df, class),
    결측값_개수 = sapply(df, function(x) sum(is.na(x))),
    결측치_비율 = sapply(df, function(x) round((sum(is.na(x)) / nrow(df)) * 100, 2)),
    고유값_개수 = sapply(df, function(x) length(unique(x[!is.na(x)]))),
    stringsAsFactors = FALSE
  )
  print(paste("데이터셋 형상:", paste(dim(df), collapse = " x ")))
  return(summary_table)}
resumetable(df)
```

[1] "데이터셋 형상: 3116945 x 21"

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.root	character	2757023	88.45	38
stem.surface	character	1980861	63.55	60
stem.color	character	38	0.00	59
veil.type	character	2957493	94.88	22
veil.color	character	2740947	87.94	24
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

2.1 결측치 처리

결측치제거

[1] "데이터셋 형상: 3116945 x 21"

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.root	character	2757023	88.45	38
stem.surface	character	1980861	63.55	60
stem.color	character	38	0.00	59
veil.type	character	2957493	94.88	22
veil.color	character	2740947	87.94	24
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

```
# 결측치 비율이 50% 이상인 열 확인
columns_to_drop = row.names(resumetable(df)[resumetable(df)$'결측치_비율' >= 50, ])
```

```
# 결과 출력
print(columns_to_drop)
```

```
[1] "stem.root" "stem.surface" "veil.type" "veil.color" "spore.print.color"
```


2.1 결측치 처리

3. 식용 가능한 버섯을 확인하는 방법

버섯을 채집할 때, 가장 중요한 것은 식용 가능 여부를 정확히 식별하는 것입니다. 다음의 가이드라인을 따르면 안전하게 식용 가능한 버섯을 확인할 수 있습니다.

(1) 외형적 특징

버섯의 모양, 색상, 크기, 향, 질감 등을 세밀히 관찰합니다. 특히 다음과 같은 요소를 주의 깊게 살펴보세요:

- **갓:** 갓의 색상, 크기, 모양을 확인합니다. 갓 아래의 주름살, 홈, 혹은 매끈한 표면 등을 관찰합니다.
- **자루:** 자루의 굵기, 길이, 표면의 무늬 등을 확인합니다.
- **포자:** 포자의 색상은 식별에 중요한 요소입니다. 종종 포자를 문지르면 색상이 변하거나 잔여물이 남습니다.

출처: <https://teaestar.tistory.com/entry/%EB%B2%84%EC%84%AF-%EC%97%B0%EA%B5%AC%EA%B0%80%EC%9D%98-%EC%84%B8%EA%B3%84-%EB%B2%84%EC%84%AF-%EC%A2%85%EB%A5%98%EC%99%80-%EC%8B%9D%EC%9A%A9-%EA%B0%80%EB%8A%A5%ED%95%9C-%EB%B2%84%EC%84%AF-%ED%99%95%EC%9D%B8-%EB%B0%A9%EB%B2%95>

2.1 결측치 처리

결측치제거

```
[1] "데이터셋 형상: 3116945 x 21"
```

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.root	character	2757023	88.45	38
stem.surface	character	1980861	63.55	60
stem.color	character	38	0.00	59
veil.type	character	2957493	94.88	22
veil.color	character	2740947	87.94	24
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

```
[1] "stem.root" "stem.surface" "veil.type" "veil.color" "spore.print.color"
```

#결측치 비율이 50%이상인 열 제거(포자색상 제외)

```
columns_to_drop = columns_to_drop[!columns_to_drop %in% ('spore.print.color')]  
df_cleaned = df[, !(names(df) %in% columns_to_drop)]  
colnames(df_cleaned)
```


2.1 결측치 처리

```
resumetable(df_cleaned)
```

[1] "데이터셋 형상: 3116945 x 17"

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.color	character	38	0.00	59
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4



2.1 결측치 처리

```
resumetable(df_cleaned)
```

[1] "데이터셋 형상: 3116945 x 17"

데이터_타입 결측값_개수 결측치_비율 고유값_개수

class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.color	character	38	0.00	59
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

결측치 채우기

#결측치 비율이 높은 컬럼 missing으로 대체

```
df_cleaned$gill.spacing[is.na(df_cleaned$gill.spacing)] = "Missing"
```

```
df_cleaned$spore.print.color[is.na(df_cleaned$spore.print.color)] = "Missing"
```


2.1 결측치 처리

결측치 채우기

```
resumetable(df_cleaned)
```

```
[1] "데이터셋 형상: 3116945 x 17"
```

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
--	--------	--------	--------	--------

class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.color	character	38	0.00	59
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

```
# 데이터프레임에서 범주형 및 연속형 열 분리
```

```
categorical_columns = names(df_cleaned)[apply(df_cleaned, is.character)]
```

```
numerical_columns = names(df_cleaned)[apply(df_cleaned, is.numeric)]
```


2.1 결측치 처리

결측치 채우기

```
resumetable(df_cleaned)
```

```
[1] "데이터셋 형상: 3116945 x 17"
```

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
--	--------	--------	--------	--------

class	factor	0	0.00	2
cap.diameter	numeric	4	0.00	3913
cap.shape	character	40	0.00	74
cap.surface	character	671023	21.53	83
cap.color	character	12	0.00	78
does.bruise.or.bleed	character	8	0.00	26
gill.attachment	character	523936	16.81	78
gill.spacing	character	1258435	40.37	48
gill.color	character	57	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.color	character	38	0.00	59
has.ring	character	24	0.00	23
ring.type	character	128880	4.13	40
spore.print.color	character	2849682	91.43	32
habitat	character	45	0.00	52
season	character	0	0.00	4

```
# 데이터프레임에서 범주형 및 연속형 열 분리
```

```
categorical_columns = names(df_cleaned)[sapply(df_cleaned, is.character)]
```

```
numerical_columns = names(df_cleaned)[sapply(df_cleaned, is.numeric)]
```

```
# 범주형 변수: 최빈값으로 결측값 채우기
```

```
for (col in categorical_columns) {  
  mode_value = names(sort(table(df_cleaned[[col]]), decreasing = TRUE))[1]  
  df_cleaned[[col]][is.na(df_cleaned[[col]])] = mode_value  
}
```

```
# 연속형 변수: 중앙값으로 결측값 채우기
```

```
for (col in numerical_columns) {  
  median_value = median(df_cleaned[[col]], na.rm = TRUE)  
  df_cleaned[[col]][is.na(df_cleaned[[col]])] = median_value  
}
```

```
resumetable(df_cleaned)
```

```
[1] "데이터셋 형상: 3116945 x 17"
```

	데이터_타입	결측값_개수	결측치_비율	고유값_개수
--	--------	--------	--------	--------

class	factor	0	0.00	2
cap.diameter	numeric	0	0.00	3913
cap.shape	character	0	0.00	74
cap.surface	character	0	0.00	83
cap.color	character	0	0.00	78
does.bruise.or.bleed	character	0	0.00	26
gill.attachment	character	0	0.00	78
gill.spacing	character	0	0.00	49
gill.color	character	0	0.00	63
stem.height	numeric	0	0.00	2749
stem.width	numeric	0	0.00	5836
stem.color	character	0	0.00	59
has.ring	character	0	0.00	23
ring.type	character	0	0.00	40
spore.print.color	character	0	0.00	33
habitat	character	0	0.00	52
season	character	0	0.00	4

2.2 고유값 처리

```
# 빈도 낮은 범주를 "unknown"으로 대체하는 함수
replace_infrequent_categories = function(df, column, threshold = 70) {
  value_counts = table(df[[column]])
  infrequent = names(value_counts[value_counts <= threshold])
  df[[column]] = sapply(df[[column]], function(x) { if (x %in% infrequent) {return("Unknown")} else {return(x)} })
  return(df)}
# 범주형 열 처리
for (col in categorical_columns) {
  df_cleaned = replace_infrequent_categories(df_cleaned, col)}

resumetable(df_cleaned)
```

[1] "데이터셋 형상: 3116945 x 17"

데이터_타입 결측값_개수 결측치_비율 고유값_개수

class	factor	0	0	2
cap.diameter	numeric	0	0	3913
cap.shape	character	0	0	74
cap.surface	character	0	0	83
cap.color	character	0	0	78
does.bruise.or.bleed	character	0	0	26
gill.attachment	character	0	0	78
gill.spacing	character	0	0	49
gill.color	character	0	0	63
stem.height	numeric	0	0	2749
stem.width	numeric	0	0	5836
stem.color	character	0	0	59
has.ring	character	0	0	23
ring.type	character	0	0	40
spore.print.color	character	0	0	33
habitat	character	0	0	52
season	character	0	0	4



[1] "데이터셋 형상: 3116945 x 17"

데이터_타입 결측값_개수 결측치_비율 고유값_개수

class	factor	0	0	2
cap.diameter	numeric	0	0	3913
cap.shape	character	0	0	8
cap.surface	character	0	0	14
cap.color	character	0	0	13
does.bruise.or.bleed	character	0	0	3
gill.attachment	character	0	0	9
gill.spacing	character	0	0	5
gill.color	character	0	0	13
stem.height	numeric	0	0	2749
stem.width	numeric	0	0	5836
stem.color	character	0	0	14
has.ring	character	0	0	3
ring.type	character	0	0	10
spore.print.color	character	0	0	9
habitat	character	0	0	9
season	character	0	0	4

3.정제된 데이터 시각화

```
#시각화 라이브러리 불러오기
library(ggplot2)
#정제된 데이터 이름 재지정
df1 = df_cleaned
```

```
# 범주형 데이터 시각화
plot_categorical <- function(data, categorical_columns) {
  # 한 화면에 여러 그래프 배치
  par(mfrow = c(ceiling(length(categorical_columns) / 5), 5)) # 3열씩 배치
  for (col in categorical_columns) {
    # 막대 그래프 생성
    barplot(
      table(data[[col]]),
      col = "skyblue",
      xlab = col,
      las = 1 # x축 텍스트 가로로 설정
    )
  }
  # 그래프 레이아웃 초기화
  par(mfrow = c(1, 1))
}

# 실행
plot_categorical(df1, categorical_columns)
```













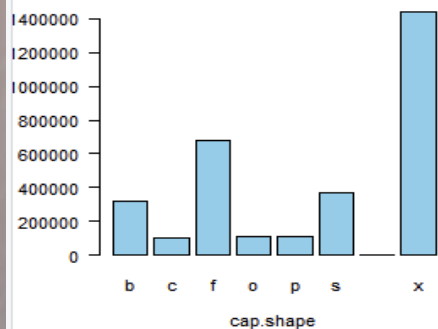
```
# 연속형 데이터 시각화
plot_numerical <- function(data, numerical_columns) {
  # 한 화면에 여러 그래프 배치
  par(mfrow = c(ceiling(length(numerical_columns) / 3), 3)) # 3열씩 배치
  for (col in numerical_columns) {
    # 히스토그램 생성
    hist(
      data[[col]],
      col = "lightblue",
      xlab = col,
      ylab = "Frequency",
      breaks = 30 # 구간 수 설정
    )
  }
}

# 실행
plot_numerical(df1, numerical_columns)
```

고유값 별 개수(빈도수)


3.정제된 데이터 시각화

막대 그래프



3.정제된 데이터 시각화

히스토그램




4. 모델링 - RandomForest

R에서는 메모리 부족 문제-> colab에서 진행



MCC Score: 0.9820591903285676





감사합니다!!

